Table de Hachage

Vincent Aranega vincent.aranega@genmymodel.com

22 février 2018

Outline

- 1 Pourquoi une nouvelle structure?
- 2 Table à adressage direct
- 3 Table de hashage
- 4 Collisions

Temps d'accés aux éléments

Pour trouver la position d'un élément e dans une structure de donnée de n éléments :

- 1 Liste : comparaison de la valeur des éléments de la liste avec e
 - au pire : comparaison jusqu'au dernier élément
 - recherche en O(n)
- 2 Arbre : comparaison de la valeur des éléments de l'arbre avec e
 - au pire : comparaison jusqu'à une feuille
 - recherche en O(log(n))
- → dépend du nombre d'éléments dans le TDA
- \rightarrow si $n \nearrow$ alors temps de la recherche \nearrow

Dans l'idéal

Pour trouver la position d'un élément e dans un ensemble de n éléments :

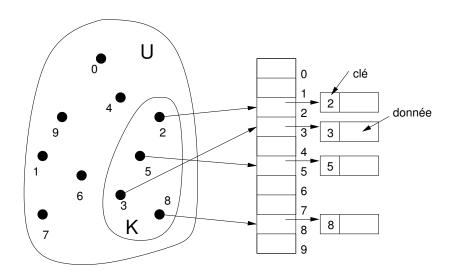
- accès direct à e
- un seul accès pour accéder à e
- recherche en O(1)
- \rightarrow ne dépend pas de nombre d'éléments n
- $\rightarrow \forall n$ temps de la recherche rapide
- ightarrow même si $n \nearrow$ alors temps de la recherche = 1

Outline

- 1 Pourquoi une nouvelle structure?
- 2 Table à adressage direct
- 3 Table de hashage
- 4 Collisions

Principe

- $U = \{0, 1, \dots, m-1\}$ est l'univers de tout les éléments/clés
- *K* est un sous ensemble dynamique de *U* représentant les clés effectivement cherchées/manipulées
- \rightarrow Technique simple si l'univers des clés U est petit
 - Représentation : table à adressage directe T[0...m-1]
 - Chaque indice de *T* correspond à une clé dans *U*
 - 2 éléments ne peuvent avoir la même clé



Problèmes

- Si *U* est grand, *T* ne tient pas en mémoire
- Si $|K| \ll |U|$ alors gaspillage de la mémoire
- ightarrow En pratique, quasi impossible à utiliser, solution à conserver lorsque U est petit et |K| est sensiblement égal à |U|

Outline

- 1 Pourquoi une nouvelle structure?
- 2 Table à adressage direct
- 3 Table de hashage
- 4 Collisions

Principe

- la place d'un élément dans la table est calculée à partir de sa propre valeur
- calcul réalisé par une fonction de hachage : transforme la valeur de l'élément en une adresse dans un tableau
- recherche d'un élément : nombre constant de comparaisons O(1). Ne dépend pas du nombre d'éléments dans le tableau

Fonction de hachage

- transforme la valeur d'un élément en position
- doit être facilement calculable (temps d'exécution de la fonction rapide sinon on perd le bénéfice de l'accès en O(1))
- Pour une table T et un élément e \exists une fonction de hachage h telle que T[h(e)] = e (si $e \in T$)

Attention

h est une fonction déterministe sinon on ne pourrait pas retrouver nos données

- Ensemble *K*
 - Ensemble des éléments à stocker
 - { serge, odile, luc, anne, annie, julie, basile, paula, marcel, elise }
- Table T avec n
 - taille de la table
 - **1**3

Rôle de la fonction de hachage h

 \rightarrow associer à chaque élément e une position $h(e) \in [0..12]$

Exemple d'algorithme de fonction h:

- 1 Attribuer aux lettres a, b, \ldots, z les valeurs $1, 2, \ldots, 26$
- $res = \sum valeurs des lettres de <math>e$
- res = res + nombre de lettres de e
- 4 $res = res \mod(n)$ (ici n = 13)

La position de l'élément serge est donnée par h(serge)

- h(serge) = (54 + 5) mod 13 = 7
- serge est à la position 7 dans la table de hachage

De même:

- h(odile) = (45+5) mod 13 = 11
- h(luc) = (36+3) mod 13 = 0
- h(anne) = (34 + 4) mod 13 = 12
- h(annie) = (43 + 5) mod 13 = 9
- h(jean) = 8, h(julie) = 10, h(basile) = 2, h(paule) = 4, h(elise) = 3, h(marcel) = 6

0	Luc			
1				
2	Basile			
3	Elise			
4	Paula			
5				
6	Marcel			
7	Serge			
8	Jean			
9	Annie			
10	Julie			
11	Odile			
12	Anne			

serge?

0	luc			
1				
2	basile			
3	elise			
4	paula			
5				
6	marcel			
7	serge			
8	jean			
9	annie			
10	julie			
11	odile			
12	anne			
12	anne			

serge?
$$\rightarrow h(serge) = 7$$

0	luc			
1				
2	basile			
3	elise			
4	paula			
5				
6	marcel			
7	serge			
8	jean			
9	annie			
10	julie			
11	odile			
12	anne			

Opération sur les tables de hachage

T[h(e)] = NULL;

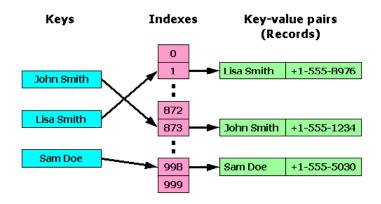
```
put(T, e)
    insère une valeur e dans la table T
    T[h(e)] = e;

get(T, e)
    retourne la valeur e si elle est présente dans T, NULL sinon
        (en considérant que chaque case du tableau à été init à NULL
    return T[h(e)];

remove(T, e)
    supprime l'entrée e de la table T
```

Stockage d'informations complémentaires

- La clé sert à rechercher l'indice dans le tableau T
- Actuellement clé = valeur stockée
- Possible d'associer d'autres informations à la clé



Opération sur les tables de hachage

- On considère une structure {key, value} comme élément de la table
- put(T, key, val)
 - insère un couple key, val dans la table T
 - T[h(key)] = couple(key, val);
- get(T, key)
 - retourne la valeur val associée à key si elle est présente dans T, NULL sinon
 - return T[h(key)] != NULL ? T[h(key)].value : NULL; (T[h(key)] retourne un couple)
- remove(T, key)
 - supprime l'entrée *key* de la table *T*
 - T[h(key)] = NULL;

Outline

- 1 Pourquoi une nouvelle structure?
- 2 Table à adressage direct
- 3 Table de hashage
- 4 Collisions

Collision

Comme |U| >> n (n taille de T) \rightarrow collision :

- $\exists k, k' \in U \mid h(k) = h(k') \land k \neq k'$
- Important de trouver la bonne fonction h
- h est dépendant des valeurs à stocker

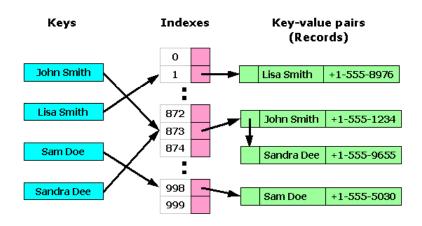
Résolution

Diverses solutions:

- Chaînage
- Adressage ouvert

Solution par chaînage

- Chaque valeur hachée est placée dans une liste
- La case *T*[*i*] contient le pointeur vers la liste des éléments de clés *k*
- Si T[i] ne désigne rien, alors il pointe sur NULL



Opération sur les tables de hachage

- On considère une structure {key, value} comme élément de la liste contenue par chaque case de T
- put(T, key, val)
 - on ajoute le couple (key, val) en tête de la liste chaînée à la position h(k) du tableau
 - ajout_tete(T[h(key)], couple(key, val));
- get(T, key)
 - on cherche la *key* dans la liste située à h(key) (recherche dans liste de couple)
 - couple = list_find(T[h(key)], key);
 return couple != NULL ? couple.value : NULL;
- remove(T, key)
 - on supprime le couple (key, val) situé de la liste contenue en h(key)
 - supp(T[h(key)], key);

Conclusion

- Ajout d'informations et recherche efficace
- Association clé, valeur
- Valeurs ordonnable ou non (pas obligatoire)
- Dépendant d'une fonction de hachage
- Difficulté → déterminer fonction de hachage

Comparaison

	Moyenne			
	recherche	insertion	suppression	
liste	O(n)	O(1)	O(n)	
arbres binaires	O(log n)	$O(\log n)$	$O(\log n)$	
tables de hachage	O(1)	O(1)	O(1)	

	Pire cas			
	recherche	insertion	suppression	
liste	O(n)	O(1)	O(n)	
arbres binaires	O(n)	O(n)	O(n)	
tables de hachage	<i>O</i> (<i>n</i>)	O(n)	O(n)	

Références

- Algorithme et Structure de données Jean-Charles Régin
- Les tables de hachage Christophe Gonzales, Pierre-Henri Wuillemin
- Tables de hachage ENSIEE
- Table de hachage B. Jacob
- Les Tables de Hachage Jean-March Nicod